

Laboratorio 03: Clasificación de Género y Estimación de Edad con Redes Convolucionales

Asignatura: *Deep Learning* (2026-01)

Profesor: Dr. Juan Bekios Calfa

1nd Víctor Jopia
Escuela de Ingeniería
Universidad Católica del Norte
ITI

victor.jopia01@alumnos.ucn.cl

2nd Kevin Silva
Escuela de Ingeniería
Universidad Católica del Norte
ITI

kevin.silva@alumnos.ucn.cl

Resumen—Este trabajo estudia simultáneamente la clasificación binaria de género y la estimación de edad a partir de imágenes faciales del conjunto UTKFace. Se compararon cinco estrategias bajo una partición y protocolo comunes: modelos clásicos con PCA, una red multicapa, una CNN simple, ResNet18 con extractor congelado y ResNet18 con ajuste fino. Además, se realizaron ablaciones sobre PCA, dropout, aumentación, tasa de aprendizaje, cantidad de bloques descongelados y ponderación de la pérdida de edad. Sobre 3,557 imágenes de prueba, el mejor resultado de género correspondió a ResNet18 con dos bloques descongelados, con accuracy y F1 de 0,9255. La mejor estimación de edad se obtuvo con ResNet18 y $\lambda_{\text{edad}} = 0,1$, con MAE de 5,85 años, RMSE de 8,20 y $R^2 = 0,8232$, manteniendo un accuracy de género de 0,9165.

Los resultados muestran que el ajuste fino y el balance entre tareas son más determinantes que aumentar indiscriminadamente el número de parámetros. Se incluyó, finalmente, una aplicación Streamlit para ejecutar el modelo sobre imágenes nuevas.

I. INTRODUCCIÓN

La inferencia de atributos faciales mediante técnicas de visión por computador constituye un problema relevante dentro del aprendizaje supervisado, ya que permite abordar simultáneamente tareas de clasificación y regresión a partir de una misma imagen de entrada. En este contexto, el conjunto de datos UTKFace proporciona imágenes faciales etiquetadas con edad y género, lo que lo convierte en un escenario adecuado para evaluar diferentes enfoques de modelado.

En este trabajo, el género se aborda como una tarea de clasificación binaria, mientras que la estimación de la edad se plantea como un problema de regresión. El tratamiento conjunto de ambas tareas permite estudiar el aprendizaje de representaciones compartidas, analizar la interacción entre objetivos de distinta naturaleza y comparar el desempeño de métodos clásicos, redes neuronales multicapa, redes convolucionales y modelos basados en transferencia de aprendizaje.

A partir de este planteamiento, el objetivo general fue implementar y comparar estrategias de complejidad creciente bajo un protocolo experimental justo y reproducible. Para ello, se preparó el conjunto de datos UTKFace extrayendo las

etiquetas desde el nombre de los archivos, se entrenaron cinco configuraciones de modelos, se evaluó de manera independiente el desempeño en clasificación y regresión mediante métricas apropiadas, se realizaron estudios de ablación para analizar la influencia de distintos componentes y, finalmente, se desarrolló una aplicación en Streamlit para realizar inferencias sobre nuevas imágenes.

El desarrollo experimental se realizó utilizando Python y las bibliotecas PyTorch, torchvision, scikit-learn y OpenCV, mientras que Streamlit se empleó para implementar la interfaz de usuario.

El alcance de este trabajo es experimental y educativo. Las etiquetas binarias de género corresponden exclusivamente a las anotaciones disponibles en el conjunto de datos y no representan la identidad de género de las personas. Asimismo, los modelos pueden reflejar los sesgos presentes en los datos de entrenamiento, por lo que sus predicciones no deben emplearse para respaldar decisiones de alto impacto.

II. MARCO TEÓRICO

- **Clasificación y regresión.** La clasificación consiste en asignar una observación a una de un conjunto finito de categorías, mientras que la regresión busca estimar una variable continua. En este laboratorio, la clasificación de género se aborda mediante dos logits optimizados con la función de pérdida de entropía cruzada (*Cross-Entropy Loss*), donde la clase predicha corresponde al logit de mayor valor. La estimación de la edad se plantea como un problema de regresión y se optimiza utilizando la función *Smooth L1 Loss*, la cual combina las ventajas de los errores absoluto y cuadrático, reduciendo la sensibilidad frente a valores atípicos.
- **Aprendizaje multitarea.** El aprendizaje multitarea consiste en entrenar un único modelo para resolver simultáneamente varias tareas relacionadas, compartiendo una representación interna y utilizando cabezas de salida

independientes para cada una. La función de pérdida se define como:

$$\mathcal{L} = \mathcal{L} * \text{CE}(g, \hat{g}) + \lambda * \text{edad}, \mathcal{L}_{\text{SmoothL1}}(a, \hat{a}), \quad (1)$$

donde λ_{edad} controla la contribución relativa de la tarea de regresión. Un valor reducido prioriza la clasificación, mientras que un valor elevado otorga mayor importancia a la estimación de la edad, pudiendo afectar el equilibrio entre ambas tareas.

- **Redes convolucionales y transferencia de aprendizaje.** Las redes neuronales convolucionales (CNN) aprovechan la estructura espacial de las imágenes mediante filtros compartidos, lo que reduce significativamente el número de parámetros respecto de una red multicapa aplicada directamente sobre píxeles aplanados. Por su parte, ResNet incorpora conexiones residuales que facilitan el entrenamiento de redes profundas al favorecer la propagación del gradiente [1]. La transferencia de aprendizaje consiste en reutilizar un modelo previamente entrenado sobre un conjunto de datos de gran escala, adaptándolo posteriormente a una tarea específica mediante el congelamiento o ajuste parcial de sus parámetros.
- **Métricas de evaluación.** El desempeño en clasificación suele evaluarse mediante *accuracy*, precisión, *recall*, puntuación F1 y matriz de confusión, las cuales permiten analizar tanto el rendimiento global como el comportamiento por clase. En problemas de regresión son habituales el error absoluto medio (MAE), la raíz del error cuadrático medio (RMSE) y el coeficiente de determinación (R^2). Mientras el MAE expresa el error promedio en las mismas unidades de la variable objetivo, el RMSE penaliza con mayor intensidad los errores de gran magnitud y R^2 cuantifica la proporción de la variabilidad explicada por el modelo.

III. METODOLOGÍA

III-A. Dataset, etiquetas y partición

Se utilizó la versión *Aligned & Cropped Faces* del conjunto de datos UTKFace [2]. Cada imagen sigue el formato de nombre `edad_genero_raza_fecha.jpg`, a partir del cual se extrajeron las variables de edad y género. En particular, el género se encuentra codificado de forma binaria, donde 0 corresponde a masculino y 1 a femenino según la anotación original del dataset.

Se implementó un analizador de nombres para filtrar archivos con formato inválido, obteniéndose un total de 23.705 imágenes válidas. Posteriormente, el conjunto completo se barajó mediante una permutación determinista con semilla 42 para garantizar reproducibilidad.

La partición del dataset se realizó de forma aproximada en 70 % para entrenamiento, 15 % para validación y 15 % para prueba, obteniéndose los subconjuntos mostrados en **Anexo: Tabla I** y **Anexo: Tabla II**. No se aplicó estratificación explícita; sin embargo, la distribución resultante de género se mantuvo relativamente balanceada. En contraste, la distribución de edad presentó un sesgo hacia el rango de 20 a 39

años, lo cual fue considerado al interpretar el desempeño del modelo.

III-B. Preprocesamiento

Todas las imágenes se redimensionaron a 224×224 píxeles, se convirtieron a tensores RGB y se normalizaron utilizando la media y desviación estándar del conjunto ImageNet. La aumentación de datos se aplicó únicamente durante el entrenamiento e incluyó volteo horizontal aleatorio ($p = 0,5$) y variaciones leves de brillo, contraste y saturación (0,1). Los conjuntos de validación, prueba e inferencia utilizaron transformaciones deterministas. Para el enfoque clásico, las imágenes se transformaron a escala de grises, se redimensionaron a 64×64 píxeles y se aplanaron en un vector unidimensional.

III-C. Estrategias comparadas

- **Clásica:** Reducción de dimensionalidad mediante PCA, seguida de dos modelos independientes: Gaussian Naive Bayes para clasificación de género y regresión Ridge para edad. Se utilizaron 100 componentes principales como configuración base, junto con ablaciones en 50 y 200 componentes.
- **MLP:** Las imágenes RGB se aplanan en un vector de 150.528 dimensiones, seguido de una red multicapa con arquitectura $150,528 \rightarrow 512 \rightarrow 128$, activaciones ReLU, dropout y dos cabezas de salida independientes para clasificación y regresión.
- **CNN:** Red convolucional compuesta por tres bloques Conv-ReLU-MaxPool con 16, 32 y 64 canales respectivamente. Se utiliza pooling adaptativo a 4×4 , seguido de una capa totalmente conectada de 256 unidades compartida y dos cabezas de salida.
- **ResNet congelada:** ResNet18 preentrenada en ImageNet con backbone congelado. Se entrenan únicamente las capas de salida asociadas a las dos tareas, utilizando una representación de 512 características.
- **ResNet fine-tuning:** ResNet18 preentrenada con ajuste fino parcial, descongelando uno o dos bloques residuales finales. Se entrenan conjuntamente las cabezas de clasificación y regresión. ResNet18 preentrenada con ajuste fino parcial, descongelando uno o dos bloques residuales finales. Se entrenan conjuntamente las cabezas de clasificación y regresión.

III-D. Entrenamiento y ablaciones

Los modelos neuronales se entrenaron durante 10 épocas utilizando el optimizador Adam, con batch size de 32, weight decay de 10^{-4} y selección del mejor modelo según la menor pérdida total en validación.

La configuración base utilizó una tasa de aprendizaje de 10^{-3} y $\lambda_{\text{edad}} = 0,01$. En el caso de fine-tuning, se utilizó una tasa de aprendizaje menor (10^{-4}), junto con una variante adicional de 10^{-5} para análisis comparativo.

Las ablaciones se realizaron modificando un único componente por experimento, incluyendo: dropout, presencia o

ausencia de aumentación de datos, valores alternativos de λ_{edad} , número de componentes en PCA y cantidad de bloques descongelados en ResNet. En total, se evaluaron 20 configuraciones sobre el mismo particionado del conjunto de datos.

El desempeño final se evaluó sobre el conjunto de prueba (3.557 imágenes). Para la tarea de regresión de edad, se calcularon métricas adicionales por rangos etarios: 0–12, 13–19, 20–39, 40–59 y 60+. Se registraron predicciones individuales, tiempos de entrenamiento, número de parámetros entrenables, curvas de aprendizaje, checkpoints y el entorno completo de ejecución para garantizar reproducibilidad.

IV. RESULTADOS

IV-A. Comparación de estrategias base

Los resultados de las configuraciones base evaluadas en el conjunto de prueba se presentan en el **Anexo: Tabla III**. Estos resultados permiten analizar el comportamiento de cada familia de modelos bajo una configuración controlada antes de considerar las 20 variantes experimentales.

En este nivel de comparación, los modelos convolucionales muestran un desempeño superior a las estrategias clásicas y a la red MLP en ambas tareas. En particular, la CNN simple logra un mejor equilibrio entre capacidad representacional y costo computacional que el MLP, el cual, a pesar de su alto número de parámetros, no se traduce en mejoras consistentes en las métricas de regresión.

El enfoque basado en PCA combinado con modelos clásicos constituye la línea base más limitada en términos de representación, aunque mantiene un desempeño razonable en la clasificación de género. Este resultado confirma las limitaciones de los métodos lineales frente a datos de alta dimensionalidad como imágenes faciales.

Por otro lado, el congelamiento completo de ResNet18 reduce su capacidad de adaptación al dominio específico, resultando en un desempeño inferior al de la CNN entrenada desde cero. En contraste, el ajuste fino parcial del backbone mejora significativamente los resultados, alcanzando el mejor desempeño entre las estrategias base tanto en clasificación como en regresión, según se resume en el **Anexo: Tabla III**. Este comportamiento sugiere que la adaptación de representaciones preentrenadas al dominio facial es un factor relevante en el rendimiento final.

El análisis global de las 20 configuraciones evaluadas se presentan en **Anexo: Figura 1** y **Anexo: Figura 2**, donde se observa la influencia de distintas combinaciones de arquitectura e hiperparámetros sobre el desempeño en ambas tareas.

IV-B. Efecto de las ablaciones

Los resultados de las configuraciones analizadas se presentan en el **Anexo: Tabla IV**. En general, se observa que las modificaciones sobre la función de pérdida y el ajuste fino del backbone tienen un impacto más significativo que cambios aislados en la arquitectura o regularización. En el caso del modelo PCA, aumentar el número de componentes mejora ligeramente la estimación de edad, aunque no produce mejoras consistentes en clasificación, lo que sugiere un límite en la capacidad

representacional de métodos lineales para este problema. En el MLP, la eliminación del dropout genera variaciones leves en el desempeño, sin cambios sustanciales en la capacidad de generalización, lo que indica que su principal limitación proviene de la representación aplanada de la imagen más que de la regularización. Para la CNN, aumentar la ponderación de la tarea de edad mejora significativamente el desempeño en regresión, a costa de una leve disminución en clasificación, evidenciando el compromiso entre tareas en el aprendizaje multitarea. En el caso de ResNet congelada, la modificación de λ_{edad} no compensa la falta de adaptación del extractor de características, lo que sugiere que el ajuste del backbone es un factor más determinante que la ponderación de la pérdida. Los modelos con fine-tuning parcial del backbone obtienen los mejores resultados globales, especialmente cuando se incrementa el peso de la tarea de regresión, lo que confirma la importancia de adaptar representaciones preentrenadas al dominio específico del problema. Finalmente, reducir λ a 0,001 produjo resultados deficientes para edad: MAE 16,67 en MLP y 13,54 en CNN. El learning rate 10^{-5} de fine-tuning mantuvo un accuracy alto (0,9086), pero obtuvo MAE 14,01 y $R^2 = -0,0355$, indicio de subentrenamiento para la tarea de edad dentro de solo 10 épocas.

IV-C. Modelo seleccionado

Se seleccionó `resnet_finetuning_lambda_high` para el despliegue final debido a su mejor compromiso entre ambas tareas. Este modelo alcanzó un accuracy de 0.9165, F1 de 0.9165, MAE de 5.85 años, RMSE de 8.20 y $R^2 = 0.8232$ en el conjunto de prueba.

La matriz de confusión del modelo se presenta en **Anexo: Figura: 3**, donde las filas corresponden a las clases reales y las columnas a las predicciones. Esto equivale a 297 errores de clasificación sobre un total de 3.557 imágenes, lo que indica un desempeño consistente en la tarea de edad tal como se muestra en **Anexo: Figura: 4**.

El análisis de las curvas de entrenamiento que se puede ver en **Anexo: Figura: 5** muestra que la menor pérdida de validación se alcanzó en la época 4 (0.7507), siendo coherente con **Anexo: Figura: 6** y **Anexo: Figura: 7**. A partir de este punto, la pérdida de entrenamiento continuó disminuyendo desde 0.6745 hasta 0.4304, mientras que la pérdida de validación se mantuvo oscilante y terminó en 0.7824. Este comportamiento evidencia un sobreajuste moderado, lo que justifica la selección del checkpoint correspondiente a la época 4 como modelo final.

Tal como se aprecia en **Anexo: Figura: 8**, el error de regresión de edad presenta una tendencia creciente con la edad: 3.75 años en el rango 0–12, 6.72 en 13–19, 4.71 en 20–39, 7.44 en 40–59 y 10.97 en 60+. En **Anexo: Figura: 9** se puede ver que este patrón refleja una mayor dificultad del modelo en edades poco representadas, así como una tendencia a la regresión hacia la media en predicciones extremas.

V. DISCUSIÓN

Los resultados obtenidos respaldan parcialmente la jerarquía esperada entre modelos en función de su capacidad inductiva y complejidad arquitectónica. En particular, los modelos convolucionales superan a las estrategias clásicas y a la MLP debido a su capacidad de preservar la estructura espacial de las imágenes faciales, lo que resulta clave para ambas tareas.

La MLP logra mejorar el desempeño en clasificación respecto del enfoque basado en PCA, pero presenta una regresión de edad inferior a la CNN, a pesar de contar con un número significativamente mayor de parámetros. Este resultado sugiere que la cantidad de parámetros no es un indicador suficiente de capacidad de generalización, y que la estructura inductiva del modelo juega un rol determinante. Además, se observa que la mayor parte de los parámetros se concentra en las capas densas iniciales, lo que incrementa el costo computacional sin aportar necesariamente mejoras proporcionales en desempeño.

En el caso de ResNet18, el congelamiento completo del backbone limita la adaptación de representaciones preentrenadas en ImageNet al dominio específico de rostros alineados y tareas de regresión de edad. Como resultado, su desempeño es inferior al de la CNN entrenada desde cero. En contraste, el ajuste fino de capas superiores permite adaptar progresivamente las representaciones, mejorando significativamente tanto la clasificación como la regresión, con un incremento moderado en el número de parámetros entrenables.

El balance entre tareas en el aprendizaje multitarea también resulta crítico. Una ponderación baja de la pérdida de edad favorece la optimización de la clasificación de género, pero deteriora el desempeño en regresión, especialmente en edades extremas. Esto sugiere la presencia de interferencia entre tareas (negative transfer), donde una señal de gradiente dominante puede perjudicar la representación compartida. En el mejor modelo, el incremento del peso relativo de la regresión favorece una representación facial más informativa para ambas tareas, aunque esta conclusión debe interpretarse considerando la dependencia del experimento a una única semilla.

La distribución del dataset explica parte de los patrones de error observados. Aproximadamente el 50.1 % de las imágenes pertenece al rango 20–39, mientras que el grupo 13–19 está subrepresentado. El modelo tiende a cometer errores mayores en clases minoritarias, especialmente en el rango 60+, y muestra una tendencia a la regresión hacia la media en predicciones extremas. Este comportamiento es consistente con sesgo de distribución en el conjunto de entrenamiento.

Finalmente, el costo computacional no escala directamente con el número de parámetros entrenables, ya que en modelos como ResNet la mayor carga proviene del forward pass del backbone congelado. Esto explica por qué la versión congelada presenta tiempos comparables al fine-tuning. En total, el entrenamiento completo de la batería experimental requirió aproximadamente 2.28 horas, sin incluir carga de datos ni generación de artefactos. Por tanto, la selección del modelo final se basó en un equilibrio entre desempeño predictivo y costo computacional.

VI. CONCLUSIONES

Se implementó un flujo reproducible para la clasificación de género y la estimación de edad utilizando el conjunto de datos UTKFace, comparando cinco estrategias y un total de 20 configuraciones experimentales bajo un mismo protocolo de evaluación. Los resultados muestran que la complejidad del modelo influye significativamente en el desempeño, aunque no de forma estrictamente proporcional al número de parámetros.

La CNN simple constituyó una alternativa eficiente, superando tanto al enfoque clásico como a la MLP y a la ResNet18 con el extractor completamente congelado. No obstante, el mejor desempeño se obtuvo mediante ajuste fino de ResNet18, confirmando que la adaptación de representaciones preentrenadas al dominio específico de rostros resulta más beneficiosa que utilizar dichas representaciones sin modificación. Asimismo, el ajuste de la ponderación de la pérdida de edad permitió mejorar el equilibrio entre ambas tareas, obteniéndose el mejor compromiso multitarea con $\lambda_{\text{edad}} = 0,1$.

Las curvas de entrenamiento evidenciaron un sobreajuste moderado a partir de la cuarta época, lo que justificó la selección del modelo según la pérdida de validación. Además, el análisis por rangos etarios mostró que los mayores errores se concentran en edades poco representadas en el conjunto de entrenamiento, resaltando la influencia de la distribución del dataset sobre la capacidad de generalización.

En respuesta a la pregunta guía del laboratorio, los resultados indican que una estrategia simple puede ofrecer un desempeño competitivo; sin embargo, el uso de una red profunda preentrenada con ajuste fino se encuentra plenamente justificado cuando se busca maximizar simultáneamente la precisión en clasificación y la exactitud en regresión.

Entre las principales limitaciones del trabajo se encuentran el uso de una única semilla experimental, la distribución desigual de edades, la naturaleza binaria de las etiquetas de género y la ausencia de análisis de calibración y equidad. Como trabajo futuro se propone realizar múltiples repeticiones experimentales, incorporar técnicas de balanceo para la regresión de edad, aplicar estrategias de *early stopping*, evaluar arquitecturas más recientes y complementar el análisis con métricas de equidad y calibración de confianza.

VII. CÓDIGO Y REPRODUCIBILIDAD

El proyecto se organizó de forma modular, separando la configuración, el procesamiento de datos, los modelos, el entrenamiento, la evaluación, la inferencia y la aplicación de usuario. La partición del conjunto de datos se almacena en `artifacts/splits/utkface_split.json`, garantizando que todas las configuraciones experimentales utilicen exactamente las mismas imágenes de entrenamiento, validación y prueba. Asimismo, cada ejecución genera automáticamente los checkpoints del modelo, el historial de entrenamiento, las métricas de evaluación y las predicciones individuales, mientras que los resultados consolidados se exportan en formatos CSV y Markdown, evitando la transcripción manual de resultados. El entorno de ejecución y la

configuración utilizada para garantizar la reproducibilidad se presentan en Anexo: Tabla V.

La reproducción de los experimentos se realiza mediante los siguientes comandos:

```
1 conda env create -f environment.yml
2 conda activate lab03-dl-2026-01
3 python -m pytest
4 python main.py --ablations
5 streamlit run Frontend/streamlit_main.py
6
```

Código 1: Comandos principales para reproducir el proyecto.

Como demostración del modelo final se desarrolló una aplicación en Streamlit que permite cargar o capturar una imagen, detectar automáticamente el rostro, aplicar el mismo preprocesamiento utilizado durante la evaluación y estimar simultáneamente el género y la edad. El modelo se mantiene en memoria mediante mecanismos de caché para reducir los tiempos de carga y el despliegue fue preparado para Streamlit Community Cloud.

El código fuente, junto con las instrucciones de instalación y ejecución, se encuentra disponible en <https://github.com/Menderin/Taller-3-Deep-Learning>. Además, el prototipo puede utilizarse directamente desde la aplicación web desplegada en <https://reconocimiento-facial-taller-3-deep-learning.streamlit.app>. Esta organización permite reproducir los experimentos y verificar los resultados obtenidos de manera consistente.

APÉNDICE

A. Tablas

Tabla I: Distribución de etiquetas de género en los conjuntos de datos.

Conjunto	Género 0	Género 1
Entrenamiento	8.685	7.908
Validación	1.817	1.738
Prueba	1.889	1.668
Total	12.391	11.314

Tabla II: Distribución de etiquetas de edad en rangos etarios.

Conjunto	0–12	13–19	20–39	40+
Entrenamiento	2.413	797	8.316	5.067
Validación	491	186	1.737	1.141
Prueba	509	197	1.827	1.024
Total	3.413	1.180	11.880	7.232

Tabla III: Resultados de las configuraciones base en test.

Modelo	Acc.	F1	MAE	RMSE	R^2
PCA + clásicos	0,8094	0,8087	11,68	15,08	0,4026
MLP multitarea	0,8580	0,8576	12,27	16,57	0,2786
CNN simple	0,8800	0,8798	9,43	12,98	0,5572
ResNet congelada	0,8395	0,8396	10,89	14,42	0,4538
ResNet fine-tuning	0,9114	0,9113	7,32	10,09	0,7322

Tabla IV: Configuraciones destacadas en el análisis de ablaciones.

Configuración	Acc.	F1	MAE	R^2
PCA 200	0,7981	0,7981	11,24	0,4456
MLP sin dropout	0,8667	0,8665	11,63	0,3242
CNN $\lambda = 0,1$	0,8676	0,8669	8,78	0,6057
ResNet congelada $\lambda = 0,1$	0,8277	0,8263	10,51	0,4839
Fine-tuning, dos bloques	0,9255	0,9255	6,62	0,7660
Fine-tuning, $\lambda = 0,1$	0,9165	0,9165	5,85	0,8232

Tabla V: Ambiente y configuración reproducible.

Elemento	Valor
Python	3.10.20
PyTorch / torchvision	2.12.1+cu130 / 0.27.1+cu130
GPU / CUDA	NVIDIA RTX A5000 / CUDA 13.0
Semilla	42
Imagen / batch / épocas	224 × 224 / 32 / 10
Optimizador	Adam
Learning rate general	10^{-3}
Learning rate fine-tuning	10^{-4}
Weight decay	10^{-4}
λ_{edad} base	0,01

B. Figuras




Figura 1: Accuracy y F1 de género.




Figura 2: MAE y RMSE de edad.




Figura 5: Pérdida total durante el entrenamiento del modelo.




Figura 3: Matriz de confusión.




Figura 6: Pérdida de género durante el entrenamiento del modelo.




Figura 4: Edad real frente a predicha.




Figura 7: Pérdida de edad durante el entrenamiento del modelo.




Figura 8: MAE por rango etario.




Figura 9: Tiempo y parámetros entrenables.

C. Resultados Experimentales

Tabla VI: Métricas de las 20 configuraciones en el conjunto de prueba.

ID	Experimento	Acc.	F1	MAE	RMSE	R^2
E1	classical_base	0,8094	0,8087	11,68	15,08	0,4026
E1	classical_pca_50	0,7852	0,7840	12,25	15,70	0,3522
E1	classical_pca_200	0,7981	0,7981	11,24	14,52	0,4456
E2	mlp_base	0,8580	0,8576	12,27	16,57	0,2786
E2	mlp_no_dropout	0,8667	0,8665	11,63	16,04	0,3242
E2	mlp_lambda_low	0,8403	0,8405	16,67	23,07	-0,3985
E2	mlp_lambda_high	0,8386	0,8386	10,71	15,11	0,4000
E3	cnn_base	0,8800	0,8798	9,43	12,98	0,5572
E3	cnn_no_augmentation	0,8766	0,8764	10,33	13,47	0,5235
E3	cnn_no_dropout	0,8687	0,8687	9,20	12,70	0,5762
E3	cnn_lambda_low	0,8766	0,8765	13,54	19,18	0,0330
E3	cnn_lambda_high	0,8676	0,8669	8,78	12,25	0,6057
E4	resnet_frozen_base	0,8395	0,8396	10,89	14,42	0,4538
E4	resnet_frozen_no_augmentation	0,8322	0,8323	10,91	14,42	0,4533
E4	resnet_frozen_lambda_low	0,8395	0,8396	11,34	15,12	0,3989
E4	resnet_frozen_lambda_high	0,8277	0,8263	10,51	14,01	0,4839
E5	resnet_finetuning_base	0,9114	0,9113	7,32	10,09	0,7322
E5	resnet_finetuning_unfreeze_more	0,9255	0,9255	6,62	9,44	0,7660
E5	resnet_finetuning_lr_low	0,9086	0,9087	14,01	19,85	-0,0355
E5	resnet_finetuning_lambda_high	0,9165	0,9165	5,85	8,20	0,8232

D. Rúbrica de autoevaluación

Tabla VII: Tabla de autoevaluación.

Criterio	¿Cumplido?
Introducción clara	Sí
Marco teórico adecuado	Sí
Metodología detallada	Sí
Resultados completos y visuales	Sí
Discusión crítica	Sí
Conclusiones reflexivas	Sí
Calidad y estructura del código	Sí
Presentación clara y sin errores	Sí
Reproducibilidad	Sí
Aportes adicionales	Sí

REFERENCIAS

- [1] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2016, pp. 770–778.
- [2] Z. Zhang, Y. Song, and H. Qi, "Age progression/regression by conditional adversarial autoencoder," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2017, pp. 5810–5818, dataset UTKFace.
- [3] A. Paszke, S. Gross, F. Massa *et al.*, "Pytorch: An imperative style, high-performance deep learning library," in *Advances in Neural Information Processing Systems*, vol. 32, 2019.
- [4] Streamlit, "Streamlit documentation," <https://docs.streamlit.io/>, 2026, consultado en junio de 2026.